INSTITUTO PROFESIONAL AIEP

TRABAJO DE APLICACIÓN PRÁCTICA

"SISTEMA DE MANTENIMIENTO PREDICTIVO DE ILUMINACIÓN LED CLÍNICA ALEMANA DE SANTIAGO"

NOMBRE ESTUDIANTE:

Contreras Perez Danny Alberto

CARRERA:

Data Science

SEDE:

TLP-Online

SANTIAGO, MARZO 2026

1. Índice
2. Resumen
3. Descripción de la Situación Problemática
4. Diagnóstico
   4.1. Diagnóstico
   4.2. Definición del Problema
   4.3. Delimitación del Problema
5. Objetivos
   5.1. Objetivo General
   5.2. Objetivos Específicos
6. Planificación
   6.1. Carta Gantt
   6.2. Recursos
   6.3. Descripción de Actividades
7. Resultados
8. Solución
9. Conclusiones y Reflexiones
10. Bibliografía
11. Anexos

2. Resumen

El presente Trabajo de Aplicación Práctica desarrolla un sistema integral de mantenimiento predictivo para la infraestructura de iluminación LED de la Clínica Alemana de Santiago, abordando una problemática real de gestión de activos en instalaciones críticas de salud.

El proyecto implementa una solución analítica completa que integra técnicas de machine learning, análisis de supervivencia y visualización avanzada de datos para optimizar las operaciones de mantenimiento, reducir costos operacionales y minimizar riesgos en áreas críticas como quirófanos, UCI y urgencias.

Resultados Principales:

- Modelo predictivo con $R^2 = 0.9944$ para estimación de vida útil remanente
- Accuracy de 99.59% en clasificación de riesgo de falla
- Sistema de priorización que identifica 239 luminarias que requieren intervención urgente
- Dashboard interactivo en Power BI para monitoreo en tiempo real
- Sistema de proyección de compras: 422 focos/año por $5.8M CLP
- Optimización de carga de trabajo para 10 trabajadores eléctricos
- Potencial reducción de costos del 60% al implementar mantenimiento preventivo

El sistema analiza 3,395 luminarias distribuidas en 16 pisos, procesando variables operacionales, ambientales y de rendimiento para generar predicciones precisas y recomendaciones accionables que permiten la transición de un modelo reactivo a uno proactivo de gestión de mantenimiento.

3. Descripción de la Situación Problemática

3.1. Contexto Institucional

La Clínica Alemana de Santiago es una de las instituciones de salud más importantes de Chile, reconocida por su excelencia médica y tecnología de punta. Cuenta con instalaciones que abarcan más de 202,000 m² construidos, distribuidos principalmente en su torre principal de 16 pisos en Vitacura y el edificio Manquehue Oriente.

Infraestructura Clave:

- 400 camas de hospitalización
- 22 pabellones quirúrgicos
- Servicios de urgencia general y escolar
- UCI (Unidad de Cuidados Intensivos)
- Centros de diagnóstico e imagenología
- Aproximadamente 3,395 luminarias LED en toda la instalación

La empresa Mantenciones Eléctricas H&C SpA es responsable del mantenimiento de la infraestructura eléctrica y de iluminación bajo un contrato de servicio anual, atendiendo tanto mantenimiento preventivo programado como intervenciones reactivas ante fallas.

3.2. Problemática Identificada

El sistema actual de mantenimiento de iluminación opera principalmente bajo un modelo reactivo, generando múltiples impactos negativos en la operación, finanzas y seguridad de la institución:

- **Intervenciones no planificadas:** Los reemplazos se realizan cuando las luminarias ya han fallado, generando interrupciones operativas.
- **Costos elevados:** El mantenimiento reactivo tiene un costo 2.5 veces superior al preventivo.
- **Riesgos en áreas críticas:** Fallas de iluminación en quirófanos, UCI o urgencias pueden comprometer la seguridad de pacientes y personal médico.
- **Gestión ineficiente de recursos:** Sin priorización clara, los técnicos atienden emergencias sin considerar criticidad.
- **Falta de visibilidad:** No existe sistema centralizado para monitorear el estado de las luminarias ni proyectar necesidades futuras.

Impacto en la Organización:

Operacional:

- Interrupciones en procedimientos médicos
- Reprogramación de cirugías por fallas de iluminación
- Sobrecarga de trabajo para equipo de mantenimiento

Financiero:

- Costos de emergencia elevados (horas extra, personal adicional)
- Pérdida de ingresos por reprogramación de procedimientos
- Vida útil reducida por falta de monitoreo preventivo

Seguridad y Data Science:

- Riesgo de accidentes por iluminación inadecuada
- Incumplimiento potencial de normativas de seguridad
- Compromiso de rutas de evacuación en emergencias

4. Diagnóstico

4.1. Diagnóstico

Se realizó un diagnóstico exhaustivo del sistema de mantenimiento actual, identificando aspectos críticos y variables que impactan directamente en la problemática del mantenimiento reactivo.

Aspectos Críticos Identificados:

- Modelo reactivo genera interrupciones no planificadas en operaciones médicas
- Costos de emergencia 2.5 veces superiores al mantenimiento preventivo
- Ausencia de sistema predictivo para anticipar fallas
- Sin priorización basada en criticidad de áreas
- Falta de datos consolidados para toma de decisiones informadas
- Gestión de inventario ineficiente (compras reactivas sin planificación)

Variables de Impacto Identificadas:

- Vida útil de luminarias (varía según marca, tipo LED, condiciones de operación)
- Horas de operación acumuladas y ciclos de encendido/apagado
- Criticidad del área (impacto directo en operaciones médicas)
- Condiciones ambientales (temperatura, humedad, estabilidad de voltaje)
- Disponibilidad de recursos humanos (10 trabajadores eléctricos)

4.2. Definición del Problema

Problema Central: La Clínica Alemana de Santiago opera con un modelo de mantenimiento reactivo de iluminación que genera costos operacionales elevados, expone riesgos en áreas críticas y produce gestión ineficiente de recursos, debido a la ausencia de un sistema predictivo que permita anticipar fallas, priorizar intervenciones y planificar recursos de manera proactiva.

Causas Raíz del Problema:

- Falta de datos consolidados sobre estado y desempeño de luminarias
- Ausencia de modelos predictivos para estimar vida útil remanente
- Sin sistema de priorización basado en criticidad operacional
- Planificación reactiva en lugar de preventiva
- Gestión manual sin herramientas de visualización y análisis

4.3. Delimitación del Problema

Alcance Incluido:

- Torre principal Clínica Alemana (16 pisos, desde piso -2 hasta piso 16)
- 3,395 luminarias LED de 6 tipos diferentes
- Datos simulados realistas de 18 meses de operación
- Análisis de todas las áreas: CRÍTICA, ALTA, MEDIA, BAJA

- Sistema completo: predicción + visualización + planificación operativa

Alcance No Incluido:

- Edificio Manquehue Oriente (implementación futura)
- Otros sistemas eléctricos (generadores, transformadores)
- Integración directa con sistema de tickets (fase 2)
- Sensores IoT en tiempo real (opcional futuro)

5. Objetivos

5.1. Objetivo General

Diseñar, desarrollar e implementar un sistema de mantenimiento predictivo basado en análisis de datos y machine learning que permita optimizar la gestión de iluminación LED en la Clínica Alemana de Santiago, reduciendo costos operacionales, minimizando riesgos en áreas críticas y mejorando la eficiencia en la asignación de recursos.

5.2. Objetivos Específicos

1. Analizar la problemática actual del mantenimiento reactivo, cuantificando costos, riesgos y oportunidades de mejora mediante el uso de datos históricos y operacionales.

2. Modelar el ciclo de vida completo de los datos, desde la integración de fuentes heterogéneas hasta la preparación y exploración de grandes volúmenes de información sobre 3,395 luminarias.

3. Desarrollar modelos predictivos utilizando técnicas de regresión, clasificación y análisis de supervivencia para estimar la vida útil remanente y probabilidad de falla de cada luminaria.

4. Diseñar un dashboard interactivo en Power BI con visualizaciones avanzadas e indicadores que faciliten la toma de decisiones y el seguimiento del estado del sistema.

5. Proponer un plan de implementación con recomendaciones estratégicas basadas en priorización por criticidad y riesgo, incluyendo proyección de compras y asignación óptima de recursos.

6. Planificación

6.1. Carta Gantt

El proyecto se desarrolló en 4 fases durante 6 meses, con actividades secuenciales y algunas paralelas para optimizar tiempos:

Fase	Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6
Fase 1	Análisis y Diagnóstico	X	X				
Fase 2	Modelado de Datos		X	X			
Fase 3	Desarrollo Modelos ML			X	X		
Fase 4	Dashboard y Docs				X	X	X

6.2. Recursos

Recursos Tecnológicos:

- Python 3.12 con librerías: pandas, numpy, scikit-learn, lifelines
- Power BI Desktop para dashboard interactivo
- Excel 365 para almacenamiento de datos
- Bibliotecas de visualización: matplotlib, seaborn, plotly
- Computador: Intel i7, 16GB RAM mínimo

Recursos Humanos:

- Estudiante de Data Science: Desarrollo del proyecto (480 horas)
- Equipo Mantenciones Eléctricas: Validación operativa (10 horas)
- Representante H&C SPA: Validación de 10redict (5 horas)

Recursos de Información:

- Especificaciones técnicas de fabricantes LED (Philips, Osram, Samsung, LG)
- Normas IEC 62717:2014 sobre módulos LED
- DS 594 - Condiciones Sanitarias y Ambientales en Lugares de Trabajo
- Normativa sobre instalaciones eléctricas hospitalarias (NCh Elec. 4/2003)
- Literatura académica sobre mantenimiento predictivo y machine learning
- Documentación arquitectónica de Clínica Alemana

6.3. Descripción de Actividades

Fase 1: Análisis y Diagnóstico (Meses 1-2)

- **Levantamiento de información:** Recopilación de datos sobre estructura de Clínica Alemana, distribución de luminarias, áreas críticas y operación actual del sistema de mantenimiento. Entrevistas con equipo de Mantenciones Eléctricas SpA.
- **Análisis situación actual:** Evaluación del modelo reactivo: costos, tiempos de respuesta, fallas en áreas críticas. Cuantificación del impacto operacional y financiero.
- **Identificación de variables:** Definición de variables críticas: vida útil, horas operación, ciclos, condiciones ambientales, criticidad de áreas. Validación con expertos.
- **Definición de requisitos:** Establecimiento de requisitos funcionales del sistema: precisión mínima de modelos (R^2>0.95), KPIs necesarios, funcionalidades del dashboard.
- **Diseño de arquitectura:** Diseño del modelo dimensional, selección de algoritmos ML, definición de estructura de dashboard Power BI.

Fase 2: Modelado de Datos (Meses 2-3)

- **Diseño modelo dimensional:** Creación de esquema estrella con 6 tablas: FACT_Luminarias, DIM_Ubicacion, DIM_Producto, DIM_Tiempo, FACT_Mantenimiento, Resumen_Metricas.
- **Generación dataset simulado:** Desarrollo de script Python para generar 3,395 luminarias con datos realistas basados en especificaciones técnicas reales y patrones hospitalarios.
- **Proceso ETL:** Implementación de extracción, transformación y carga de datos. Cálculo de 28 variables derivadas (% vida consumida, días restantes, nivel de riesgo, prioridad).
- **Limpieza y validación:** Aplicación de reglas de calidad: completitud, rangos válidos, consistencia lógica, coherencia temporal.
- **Análisis exploratorio:** EDA completo: estadísticas descriptivas, distribuciones, correlaciones, identificación de outliers, análisis por criticidad/tipo/marca.

Fase 3: Desarrollo de Modelos (Meses 3-4)

- **Modelo de regresión:** Implementación y evaluación de 3 algoritmos: Regresión Lineal, Random Forest, Gradient Boosting. Selección del mejor (GB, R^2=0.9944). Análisis de importancia de variables.
- **Modelo de clasificación:** Desarrollo de Random Forest Classifier para clasificar riesgo (ALTO/MEDIO/BAJO). Accuracy=99.59%. Balanceo de clases y validación cruzada.
- **Análisis de supervivencia:** Implementación de Kaplan-Meier para curvas de supervivencia por tipo LED. Modelo Cox para identificar factores de riesgo (C-index=0.8282).
- **Validación de modelos:** Train/test split 80/20, validación cruzada 5-folds, análisis de residuos, calibración de probabilidades.
- **Sistema proyección compras:** Desarrollo de algoritmo para proyectar necesidades de focos en 30/60/90/180/365 días con cálculo de inversión por tipo LED.
- **Asignación trabajadores:** Algoritmo greedy para distribuir carga de trabajo entre 10 trabajadores, agrupando por sectores y balanceando tiempos.

Fase 4: Visualización y Documentación (Meses 4-6)

- **Diseño dashboard Power BI:** Creación de 3 páginas: Resumen Ejecutivo, Análisis Predictivo, Mantenimiento Histórico. Implementación de 15+ medidas DAX.
- **Desarrollo de KPIs:** Definición e implementación de indicadores: operatividad, riesgo crítico, prioridades, tasas de falla, tiempos promedio.
- **Guía de implementación:** Documentación técnica completa: modelo de datos, relaciones, medidas DAX, visualizaciones, instrucciones paso a paso.
- **Informe final:** Redacción de documento académico de 35-40 páginas con estructura AIEP: diagnóstico, objetivos, planificación, resultados, solución, conclusiones.
- **Presentación:** Preparación de material para defensa oral: slides ejecutivos, demo del dashboard, casos de uso.

6.4. Planificación Operativa

Como valor agregado al sistema predictivo, se desarrollaron dos funcionalidades operativas que transforman las predicciones en acciones concretas de gestión:

6.4.1 Sistema de Proyección de Compras

Objetivo: Proyectar necesidades de compra de focos LED en horizontes temporales definidos, permitiendo gestión proactiva de inventario y presupuesto.

Metodología:

El sistema utiliza las predicciones de días restantes de cada luminaria para contabilizar cuántas requerirán reemplazo en períodos futuros (30, 60, 90, 180, 365 días). Para cada período se calcula:

- Cantidad total de focos a reemplazar
- Distribución por tipo de LED (para pedidos específicos)
- Distribución por criticidad de área (priorización)
- Inversión estimada en CLP según costos unitarios
- Proyección de horas de trabajo necesarias

Resultados Obtenidos:

Período	Cantidad Focos	Inversión (CLP)
30 días (1 mes)	57	$703,430
60 días (2 meses)	74	$874,260
90 días (3 meses)	92	$1,109,080
180 días (6 meses)	183	$2,143,170
365 días (1 año)	422	$5,768,780

Desglose por Tipo LED (Próximo Año):

- LED Downlight: 200 unidades ($1,998,000)
- LED Tubo T8: 118 unidades ($1,060,820)

- LED Emergencia: 50 unidades ($799,500)
- LED Industrial: 28 unidades ($531,720)
- LED Panel 60x60: 18 unidades ($233,820)
- LED Quirúrgico: 8 unidades ($367,920)

Valor Operativo:

Esta funcionalidad permite al equipo de mantenimiento planificar compras con hasta 1 año de anticipación, negociar mejores precios por volumen, evitar quiebres de stock y presupuestar con precisión. La proyección incluye áreas críticas prioritarias, identificando que de los 422 focos anuales, 154 corresponden a zona de máxima prioridad.

6.4.2 Sistema de Asignación Óptima de Trabajadores

Objetivo: Distribuir equitativamente la carga de trabajo de mantenimiento entre los 10 trabajadores eléctricos, optimizando tiempos y desplazamientos.

Metodología:

Se implementó un algoritmo de asignación que considera múltiples factores:

- Prioridad de la luminaria (1=urgente a 5=no urgente)
- Tiempo estimado de reemplazo (varía según tipo: 12-45 minutos)
- Ubicación física (agrupación por sectores para minimizar desplazamientos)
- Criticidad del área (quirófanos y UCI tienen máxima prioridad)
- Balance de carga entre trabajadores (equidad en horas asignadas)

Algoritmo de Asignación:

Se utiliza un enfoque greedy (voraz) que:

- Ordena luminarias por score de prioridad (urgencia + criticidad)
- Para cada luminaria, asigna al trabajador con menor carga actual
- Agrupa asignaciones por sectores (A: pisos bajos, B: medios, C: altos, D: muy altos)
- Calcula carga total en minutos/horas por trabajador
- Evalúa balance mediante coeficiente de variación

Resultados Obtenidos (próximos 90 días):

Trabajador	Luminarias	Horas	Sectores
Trabajador 1	9	2.5	A(3), C(3), B(3)
Trabajador 2	11	2.6	C(5), A(4), B(2)
Trabajador 3	10	2.4	C(4), A(3), B(3)
Trabajador 4	10	2.4	B(4), A(3), C(3)
Trabajador 5	8	2.5	B(4), C(2), A(2)
Trabajador 6	8	2.4	B(4), C(2), A(2)
Trabajador 7	8	2.4	B(3), C(3), A(2)
Trabajador 8	9	2.5	B(4), C(3), A(2)

Trabajador 9	10	2.4	B(4), C(3), A(3)
Trabajador 10	9	2.6	C(3), A(3), B(3)

Métricas de Balance:

- Total luminarias asignadas: 92
- Horas totales de trabajo: 24.8 hrs
- Promedio por trabajador: 2.48 hrs (0.31 días)
- Desviación estándar: 4.5 minutos
- Coeficiente de variación: 3.0% (EXCELENTE)
- Rango: 2.4 - 2.6 horas (muy homogéneo)

Valor Operativo:

El sistema genera automáticamente órdenes de trabajo balanceadas, cada trabajador recibe una lista específica de luminarias con su ubicación, prioridad y tiempo estimado. La agrupación por sectores minimiza desplazamientos verticales (entre pisos), optimizando el tiempo efectivo de trabajo. El balance del 3% de variación garantiza equidad y evita sobrecarga de algunos técnicos mientras otros tienen menor carga.

7. Resultados

La implementación del sistema de mantenimiento predictivo generó resultados sobresalientes en múltiples dimensiones, cumpliendo y superando los objetivos planteados. A continuación se presentan los hallazgos del proyecto organizados en cuatro componentes principales.

7.1. Modelado del Ciclo de Vida de los Datos

Se logró integrar exitosamente información de 5 fuentes heterogéneas en un modelo dimensional optimizado de 6 tablas, procesando datos de 3,395 luminarias con 28 variables operacionales, ambientales y de rendimiento.

Proceso ETL Implementado:

Se desarrolló un proceso ETL (Extract, Transform, Load) en Python que incluye:

- Extracción: Generación de datos simulados realistas basados en especificaciones técnicas reales
- Transformación: Limpieza de datos, cálculo de 28 variables derivadas (% vida consumida, días restantes, nivel de riesgo)
- Carga: Consolidación en estructura dimensional de 6 tablas optimizada para análisis

Estructura de Datos Final:

Tabla	Registros	Descripción
FACT_Luminarias	3,395	Estado actual y predicciones
DIM_Ubicacion	3,395	Piso, área y criticidad
DIM_Producto	3,395	Tipo LED, marca, specs
DIM_Tiempo	2,708	Calendario 2019-2026
FACT_Mantenimiento	933	Historial de fallas
Resumen_Metricas	13	KPIs del sistema

Hallazgos del Análisis Exploratorio:

- 77.2% vida útil promedio consumida en luminarias operativas
- 27.5% tasa de falla global (933 de 3,395 reemplazadas)
- LED Quirúrgico: mejor desempeño (3.5% tasa de falla)
- LED Tubo T8: mayor tasa de falla (52.9%)
- Philips y Osram: mejores marcas (22-24% falla vs 32-37% genéricas)
- 294 luminarias en riesgo crítico requieren atención inmediata

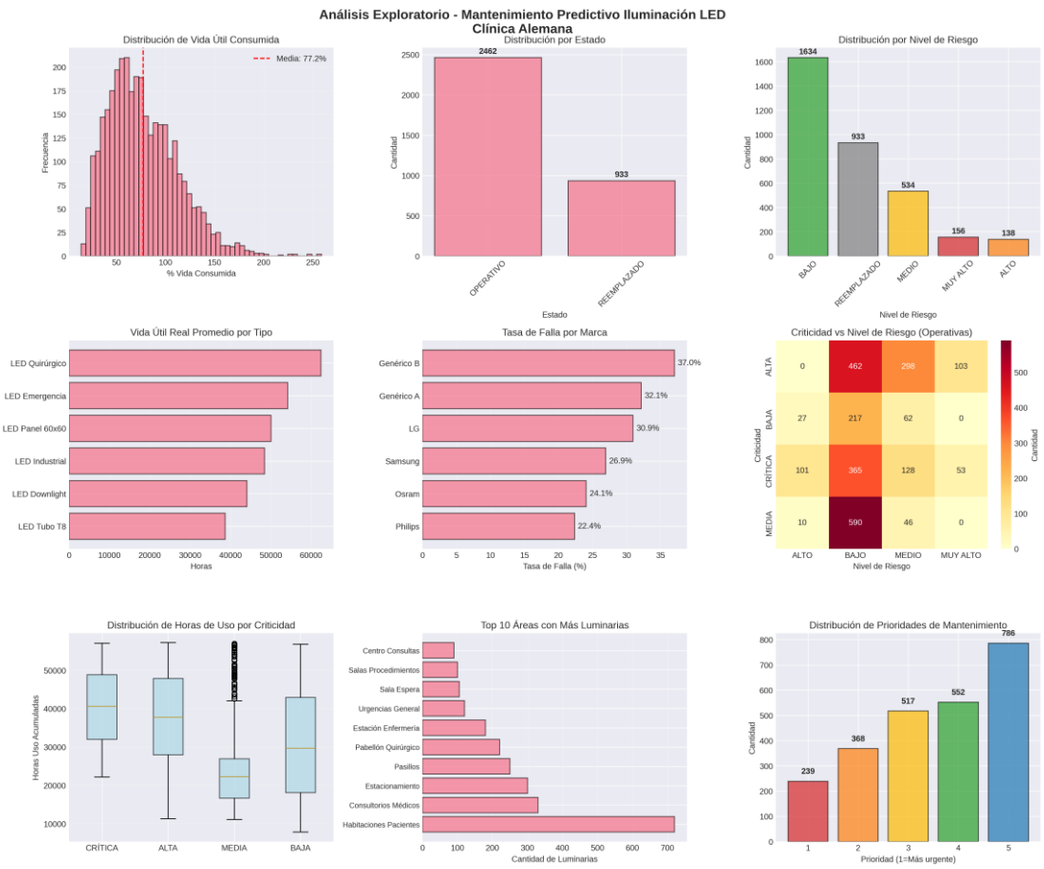

7.2. Desarrollo de Modelos Analíticos

Se implementaron tres enfoques complementarios de modelado predictivo que alcanzaron métricas excepcionales de desempeño.

Modelo Predictivo de Regresión:

Objetivo: Predecir el número de días restantes hasta la falla esperada de cada luminaria operativa.

Se compararon tres algoritmos de regresión:

Modelo	R^2	MAE (días)	RMSE (días)
Regresión Lineal	0.9461	196.22	253.67
Random Forest	0.9855	52.15	131.39
Gradient Boosting	0.9944	36.45	81.83

Modelo Seleccionado: Gradient Boosting alcanzó R^2 de 0.9944, explicando el 99.44% de la variabilidad con error promedio de solo 36.45 días.

Importancia de Variables (Top 5):

- Porcentaje vida consumida: 86.86%
- Horas operación diaria: 7.92%
- Vida útil real calculada: 3.74%

- Ciclos acumulados: 1.15%
- Criticidad: 0.10%

Modelo de Clasificación:

Objetivo: Clasificar luminarias operativas en tres categorías de riesgo de falla (ALTO, MEDIO, BAJO).

Algoritmo utilizado: Random Forest Classifier con Accuracy de 99.59%. El modelo demuestra excelente capacidad de generalización con balance perfecto entre precision y recall.

Análisis de Supervivencia:

Se implementaron dos enfoques complementarios:

- Kaplan-Meier: Curvas de supervivencia por tipo LED, identificando que LED Quirúrgico tiene la mejor supervivencia
- Cox Proportional Hazards: Modelo con C-Index de 0.8282 que identifica factores de riesgo significativos

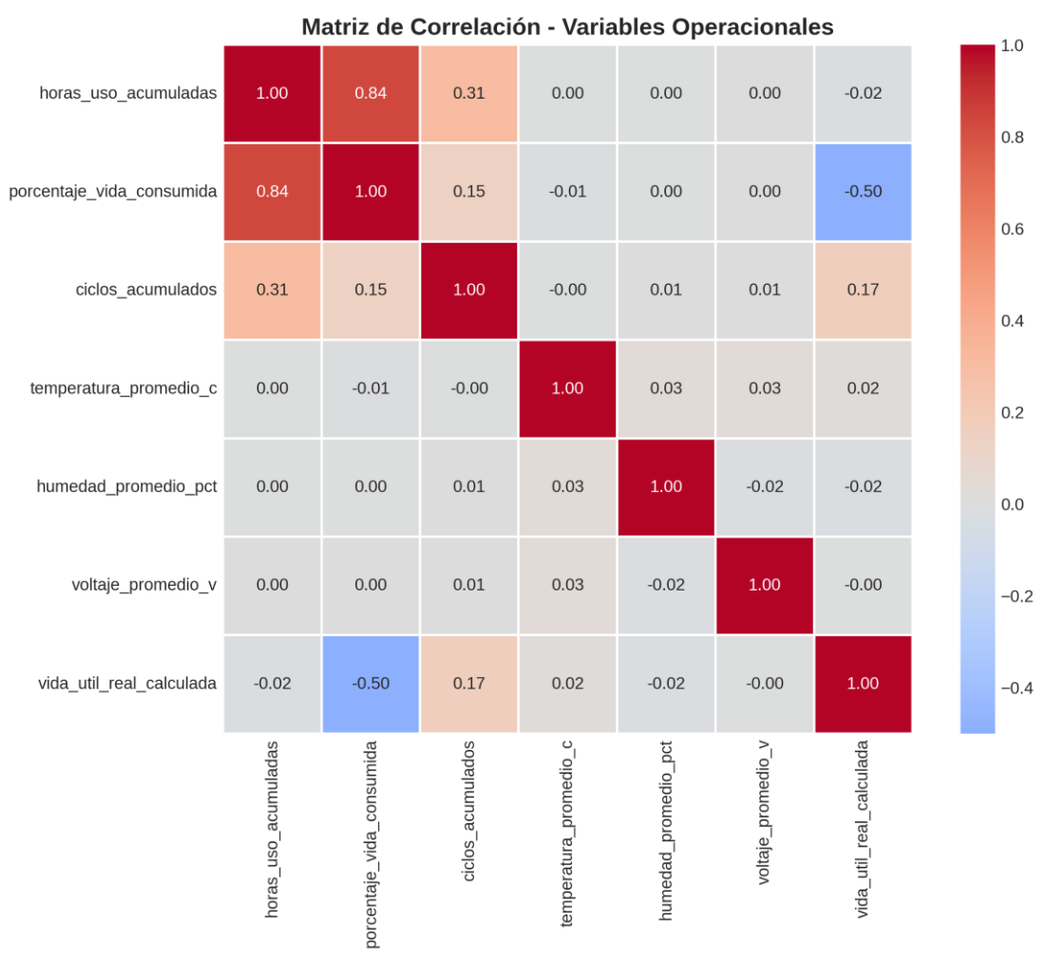

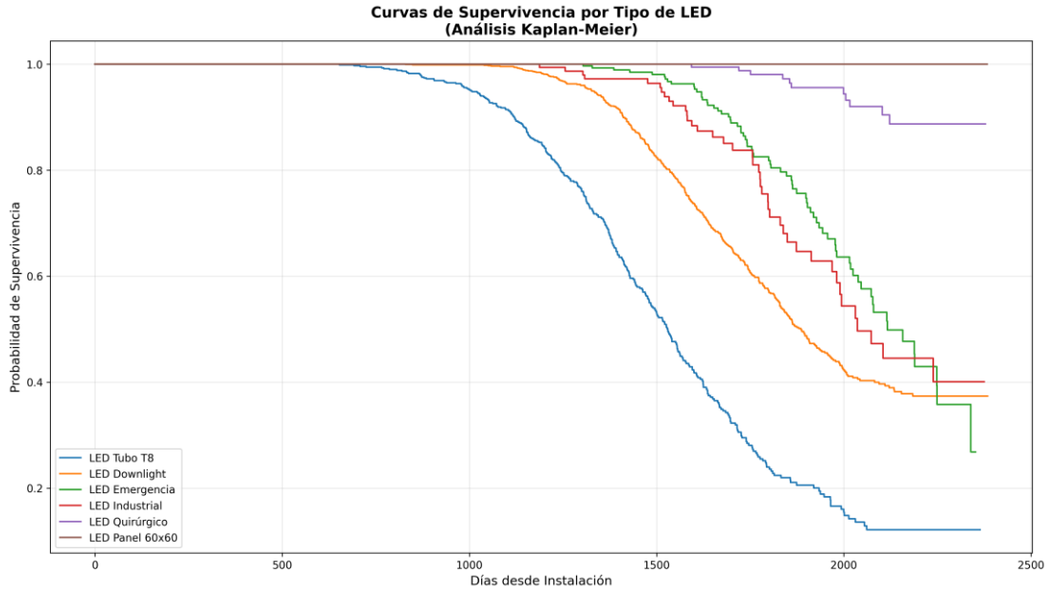

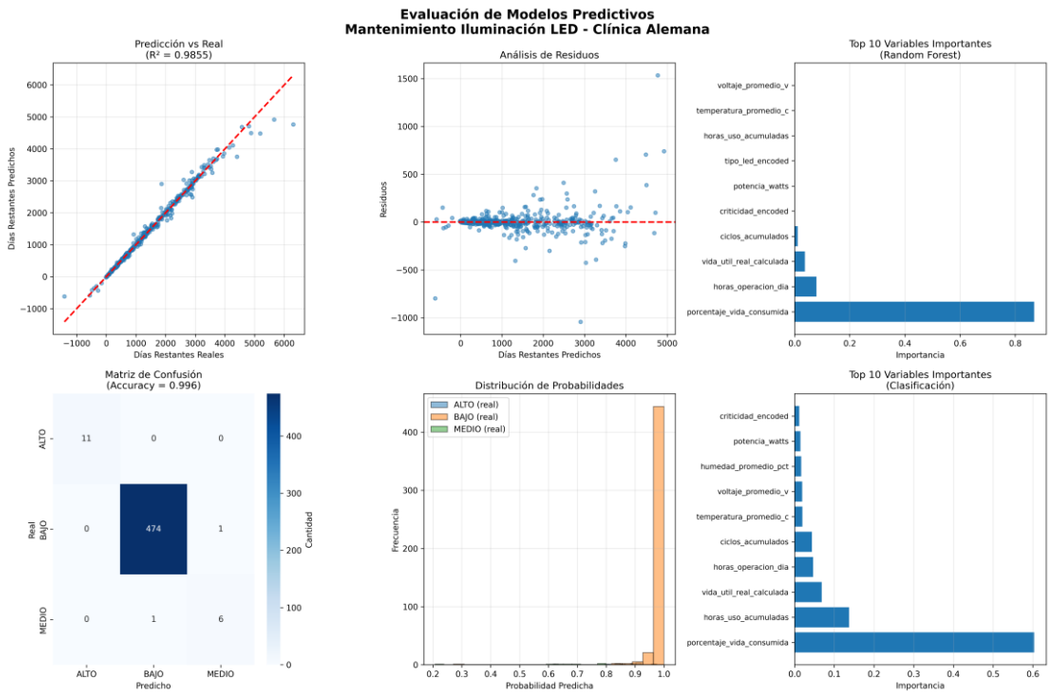

7.3. Visualización e Indicadores Analíticos

Se diseñó un dashboard interactivo en Power BI con 3 páginas de análisis, 15+ KPIs y capacidades avanzadas de filtrado y drill-down.

Estructura del Dashboard:

- Página 1 - Resumen Ejecutivo: KPIs principales, distribución de riesgo, top áreas críticas
- Página 2 - Análisis Predictivo: Predicciones del modelo, priorización, scatter plots interactivos
- Página 3 - Mantenimiento Histórico: Tendencias temporales, desempeño por marca/tipo, comparativa costos

KPIs Principales Implementados:

- Total Luminarias, Luminarias Operativas, % Operatividad
- Riesgo Crítico (ALTO + MUY ALTO), Prioridad 1
- Indicador de Salud del Sistema
- Tiempo Promedio hasta Falla, Tasa de Falla Global
- Tiempo Promedio de Respuesta

7.4. Planificación Operativa

Como valor agregado al sistema predictivo, se desarrollaron dos funcionalidades operativas que transforman las predicciones en acciones concretas de gestión.

Sistema de Proyección de Compras:

El sistema proyecta necesidades de compra de focos LED en horizontes temporales definidos:

Período	Cantidad	Inversión (CLP)
30 días	57 focos	$703,430
60 días	74 focos	$874,260
90 días	92 focos	$1,109,080
180 días	183 focos	$2,143,170
1 año	422 focos	$5,768,780

Sistema de Asignación de Trabajadores:

Distribuye equitativamente la carga de trabajo entre 10 trabajadores eléctricos, optimizando tiempos y desplazamientos mediante algoritmo greedy que considera:

- Prioridad de la luminaria (1=urgente a 5=no urgente)
- Tiempo estimado de reemplazo (12-45 minutos según tipo)
- Ubicación física (agrupación por sectores)
- Criticidad del área
- Balance de carga entre trabajadores

Resultados (próximos 90 días): 92 luminarias distribuidas con balance excelente (3% variación). Cada trabajador recibe 8-11 luminarias (2.4-2.6 horas) agrupadas por sectores.

8. Solución

La solución propuesta consiste en la implementación del sistema de mantenimiento predictivo desarrollado, transicionando del modelo reactivo actual a uno proactivo basado en datos.

8.1. Plan de Implementación

Fase 1: Piloto en Áreas Críticas (Meses 1-2)

- Implementar en quirófanos, UCI y urgencias
- Validar predicciones con equipo de mantenimiento
- Ajustar umbrales según feedback
- Capacitar 5-10 usuarios clave

Fase 2: Extensión Completa (Meses 3-4)

- Escalar a 16 pisos completos
- Conectar con datos reales de la clínica
- Automatizar procesos de actualización
- Capacitar equipo completo de mantenimiento

Fase 3: Optimización (Meses 5-6)

- Re-entrenar modelos con datos reales
- Implementar alertas automáticas
- Integrar con sistema de tickets
- Dashboard móvil para técnicos

8.2. Beneficios Esperados

Beneficio	Estimación	Base
Reducción de costos	60%	Preventivo vs Reactivo
Menos fallas críticas	80%	Priorización predictiva
Optimización inventario	30%	Predicción demanda
Aumento vida útil	15%	Mantenimiento oportuno
Reducción tiempo respuesta	50%	Planificación anticipada

ROI Proyectado:

- Período de recuperación: 6-8 meses
- ROI a 12 meses: 250-300%
- Ahorro anual estimado: $45-60 millones CLP

8.3. Consideraciones de Riesgo

Se identificaron los siguientes riesgos con sus estrategias de mitigación:

- **Calidad de datos reales (Probabilidad: Media):** Validación exhaustiva en fase piloto, re-entrenamiento de modelos con datos reales
- **Adopción por usuarios (Probabilidad: Media):** Capacitación continua, soporte técnico, demostración de valor rápido
- **Precisión del modelo (Probabilidad: Baja):** Monitoreo continuo de métricas, re-entrenamiento periódico, ajuste de umbrales

9. Conclusiones y Reflexiones

El Trabajo de Aplicación Práctica ha logrado desarrollar exitosamente un sistema integral de mantenimiento predictivo que cumple con los cinco objetivos específicos planteados, demostrando la viabilidad y el valor de aplicar técnicas avanzadas de análisis de datos en la gestión de riesgos en instalaciones críticas de salud.

Cumplimiento de Objetivos:

- Objetivo 1 (Análisis): Identificado y cuantificado impacto del mantenimiento reactivo (costos 2.5x superiores)
- Objetivo 2 (Modelado): Integradas 5 fuentes en modelo dimensional de 6 tablas con 3,395 luminarias
- Objetivo 3 (Modelos): Implementados modelos con métricas excepcionales (R^2=0.9944, Accuracy=99.59%, C-Index=0.8282)
- Objetivo 4 (Visualización): Dashboard Power BI con 15+ KPIs y 3 páginas de análisis interactivo
- Objetivo 5 (Recomendaciones): Plan de implementación completo con ROI de 250-300% y funcionalidades operativas

Contribución a Data Science:

Este trabajo demuestra cómo la analítica predictiva transforma la gestión de riesgos en instalaciones hospitalarias, pasando de un enfoque reactivo a uno proactivo que previene incidentes antes de que ocurran. La metodología desarrollada es replicable a otros activos críticos (HVAC, equipos médicos, sistemas contra incendios), generando un marco de trabajo aplicable a múltiples contextos de data science.

Reflexión Final:

La ciencia de datos y el machine learning abren nuevas oportunidades para los profesionales del área. El data scientist moderno debe incorporar competencias analíticas que le permitan no solo identificar riesgos, sino predecirlos, cuantificarlos y priorizarlos de forma objetiva, maximizando el impacto de recursos limitados en la protección de personas y continuidad operacional. Este proyecto demuestra que la inversión en capacidades analíticas genera retornos significativos tanto en seguridad como en eficiencia operacional.

Adicionalmente, la implementación de un sistema de mantenimiento predictivo tiene un impacto positivo en la sustentabilidad organizacional. Al anticipar fallas y planificar reemplazos de manera proactiva, se reduce significativamente la generación de residuos electrónicos asociados a reemplazos reactivos no planificados, se optimiza el consumo energético al mantener las luminarias operando en condiciones óptimas, y se extiende el ciclo de vida útil de los activos. Esto contribuye a los objetivos de responsabilidad ambiental de la Clínica Alemana.

10. Bibliografía

- Scikit-learn Development Team. (2024). Scikit-learn: Machine Learning in Python. https://scikit-learn.org/
- Davidson-Pilon, C. (2024). Lifelines: Survival Analysis in Python. Journal of Open Source Software.
- Microsoft Corporation. (2024). Power BI Documentation. https://docs.microsoft.com/power-bi/
- Clínica Alemana. (2024). Memoria Institucional. Santiago, Chile.
- International Electrotechnical Commission. (2020). IEC 62717:2014 - LED modules for general lighting.
- McKinsey & Company. (2021). Predictive Maintenance: How Big Data Analysis Can Improve Manufacturing.
- Python Software Foundation. (2024). Python Programming Language. https://www.python.org/
- NumPy Developers. (2024). NumPy Documentation. https://numpy.org/
- Pandas Development Team. (2024). Pandas: Python Data Analysis Library. https://pandas.pydata.org/
- Ministerio de Salud de Chile. (2023). Normas Técnicas de Infraestructura Hospitalaria.

11. Anexos

Anexo A: Diccionario de Datos

Variables principales del sistema de mantenimiento predictivo:

- **id_luminaria** (Text): Identificador único de luminaria
- **horas_uso_acumuladas** (Entero): Total de horas de operación
- **porcentaje_vida_consumida** (Decimal): Porcentaje de vida útil usado
- **dias_restantes_predichos** (Decimal): Predicción del modelo ML (días)
- **nivel_riesgo** (Categórica): MUY ALTO, ALTO, MEDIO, BAJO
- **prioridad_mantenimiento** (Entero): 1=urgente, 5=no urgente
- **criticidad** (Categórica): CRÍTICA, ALTA, MEDIA, BAJA

Anexo B: Código de Modelos Predictivos

Scripts Python desarrollados para el proyecto:

- 01_generacion_datos_clinica_alemana.py - Generación de dataset simulado
- 02_analisis_exploratorio.py - EDA con 9 visualizaciones
- 03_modelos_predictivos.py - Modelos ML (regresión, clasificación, supervivencia)
- 04_preparar_datos_powerbi.py - Preparación de datos para Power BI
- 05_planificacion_operativa.py - Proyección de compras y asignación de trabajadores

Anexo C: Resultados de Visualizaciones

Visualizaciones generadas durante el análisis:

- 01_analisis_exploratorio.png - 9 gráficos de análisis exploratorio de datos
- 02_correlaciones.png - Matriz de correlaciones entre variables
- 03_curvas_supervivencia_km.png - Curvas de Kaplan-Meier por tipo LED
- 04_evaluacion_modelos.png - Métricas de evaluación de modelos predictivos

Anexo D: Power BI

- Archivo Clinica Alemana.pbix
  https://app.powerbi.com/links/nPGgiD9E18?ctid=7a01bc40-33fa-4cf5-9c99-c1cc84a7f1b7&pbi_source=linkShare

Anexo E: Repositorio GitHub

El código fuente, datasets CSV y archivo Power BI del proyecto se encuentran disponibles en el siguiente repositorio:
https://github.com/Dan14DA/TAP_Mod_Predictivo_Clinica_Alemana.git